

UNIVERSIDADE PRESBITERIANA MACKENZIE
CURSO DE TECNOLOGIA EM CIÊNCIA DE DADOS

ANDERSON APARECIDO DA SILVA ALVES
ANDRÉIA DOMINGOS DOS SANTOS
GERSON SOARES RODRIGUES
SAMUEL BONFIM DA SILVA

RA:

10347602

10288503

10423804

10423509

APLICAÇÃO DE REDES NEURAIS CONVOLUCIONAIS PARA
RECONHECIMENTO DE FRUTAS

SÃO PAULO

2024

ANDERSON APARECIDO DA SILVA ALVES
ANDRÉIA DOMINGOS DOS SANTOS
GERSON SOARES RODRIGUES
SAMUEL BONFIM DA SILVA

APLICAÇÃO DE REDES NEURAIS CONVOLUCIONAIS PARA
RECONHECIMENTO DE FRUTAS

Análise de dados fornecidos pela plataforma Zenodo

Trabalho acadêmico para conclusão da disciplina de Projeto Aplicado II do Curso de Tecnologia em Ciência de Dados pela Universidade Presbiteriana Mackenzie.

Professor: Felipe Albino dos Santos

SÃO PAULO

2024

A001

Silva, Anderson Aparecido da Silva.

Dos Santos, Andréia Domingos.

Rodrigues, Gerson Soares.

Da Silva, Samuel Bonfim.

Análise de Frutas por meio de Redes Neurais Convolucionais (CNN) / Anderson Aparecido da Silva Alves; Andréia Domingos dos Santos; Gerson Soares Rodrigues; Samuel Bonfim da Silva - 2024. 8 f.: il.; 30 cm.

Trabalho Acadêmico (Projeto Aplicado II) – Universidade Presbiteriana Mackenzie,
Presbiteriana Mackenzie, São Paulo, 2024.

SUMÁRIO

1. INTRODUÇÃO	1
2. GLOSSÁRIO	1
3. APRESENTAÇÃO DOS DADOS.....	2
4. ANÁLISE EXPLORATÓRIA.....	2
5. TRATAMENTO DOS DADOS.....	2
6. TRANSFORMAÇÃO DOS DADOS	3
7. TREINAMENTO DOS DADOS	3
8. AVALIAÇÃO DO MODELO.....	3
9. EXPECTATIVA PARA AS PROXIMAS ENTREGAS	3
10. LINK PARA O GITHUB	3
11. REFERENCIA BIBLIOGRÁFICA	3

1. INTRODUÇÃO

O reconhecimento automático de frutas é um desafio global que afeta predominantemente o setor de comércio e logística, especialmente em supermercados e mercados de alimentos. Essa dificuldade é causada por fatores como a grande semelhança visual entre diferentes tipos de frutas e as variações ambientais, como iluminação e posição. Com o aumento da automação e da necessidade de precisão nas operações comerciais, identificar e classificar corretamente os produtos tornou-se crucial. Desde o avanço das técnicas de visão computacional, a precisão no reconhecimento de imagens tem melhorado, mas ainda existem desafios significativos. Para enfrentar esse problema, diversas soluções foram desenvolvidas, incluindo o uso de redes neurais convolucionais (CNN), que permitem o reconhecimento de frutas com alta precisão, mesmo em condições desafiadoras. Neste projeto, exploraremos a aplicação do CNN para o reconhecimento de frutas, utilizando uma base de dados robusta de 44.406 imagens coletadas em diferentes condições ambientais. A proposta inclui a análise da eficiência do modelo utilizando as frutas de situações reais, com o objetivo de melhorar a precisão e a automação no setor comercial.

2. GLOSSÁRIO

As imagens utilizadas neste projeto foram disponibilizadas pela plataforma Zenodo, (nos formatos JPG, JPEG e PNG) que estão armazenados no GitHub do projeto e analisadas nas próximas etapas;

Para este projeto, as bibliotecas utilizadas nesse trabalho até o momento têm como os seguintes objetivos:

- **os**: Manipula funcionalidades do sistema operacional, como caminhos de arquivos e diretórios.
- **torch**: Principal biblioteca para computação em tensor e aprendizado profundo em PyTorch.
- **re**: Realiza operações de expressão regular para manipulação e busca de strings.
- **cv2**: Biblioteca OpenCV para processamento de imagens e visão computacional.
- **shutil**: Facilita operações de alto nível em arquivos e coleções de arquivos, como copiar e mover.
- **random**: Gera números aleatórios e realiza operações relacionadas à aleatoriedade.
- **PIL (Image)**: Manipula imagens, como abrir, criar e salvar arquivos de imagem.
- **numpy**: Biblioteca para computação numérica, facilitando operações em arrays e matrizes.

- **torch.nn**: Fornece classes e funções para construir redes neurais em PyTorch.
- **seaborn**: Facilita a visualização de dados estatísticos com gráficos mais informativos.
- **pandas**: Manipula e analisa dados estruturados em DataFrames.
- **torch.optim**: Implementa algoritmos de otimização para treinar modelos em PyTorch.
- **matplotlib.pyplot**: Cria gráficos e visualizações de dados.
- **torchvision**: Oferece conjuntos de dados, transformações e modelos pré-treinados para tarefas de visão computacional.
- **DataLoader**: Carrega conjuntos de dados em lotes para treinamento de modelos em PyTorch.
- **torchvision.models**: Fornece modelos pré-treinados para tarefas de visão computacional.
- **sklearn.metrics**: Avalia o desempenho do modelo por meio de métricas como precisão, recall e F1-score.
- **collections.defaultdict**: Cria dicionários que fornecem um valor padrão para chaves inexistentes.
- **sklearn.model_selection**: Divide conjuntos de dados em treino e teste, e realiza validação cruzada.
- **confusion_matrix, classification_report**: Avaliam e relatam a precisão de um modelo de classificação.

3. APRESENTAÇÃO DOS DADOS

Os dados que serão apresentados nesse trabalho foram adquiridos da seguinte plataforma:

<https://zenodo.org/records/1310165>

O Dataset é composto por 44.406 imagens de frutas, coletadas em um período de 6 meses. As imagens foram feitas em um ambiente de laboratório em diferentes cenários mencionadas no artigo ao fim desse trabalho.

4. ANÁLISE EXPLORATÓRIA

Nesta etapa realizamos análises para entender os dados apresentados. Obtivemos durante o processo a quantidade de imagens por categoria de frutas, a análise de distribuição dos dados, a descrição dos dados, média, desvio padrão etc. Realizamos também a plotagem de imagens aleatórias do conjunto.

5. TRATAMENTO DOS DADOS

Nesta etapa realizamos a separação dos dados em pastas de treino, validação e teste sendo 69.98% para treino 15% para validação e 15.02% para teste. Dentro das pastas

mencionadas existem subpastas separadas em categorias de frutas, elas incluem maçã, banana, manga, goiaba etc.

6. TRANSFORMAÇÃO DOS DADOS

Usamos como métricas de transformação de dados a documentação apresentada pelo Pytorch, que apresentou uma grande eficiência aos nossos dados.

Decidimos durante o processo de pesquisa utilizar o método.

7. TREINAMENTO DOS DADOS

Decidimos durante o processo de pesquisa utilizar o método Transfer Learning da ResNet50 que apresentou excelentes resultado quando aplicados aos dados com grande diversidade de categorias.

8. AVALIAÇÃO DO MODELO

O processo de treinamento do modelo durou cerca de 8 horas e os resultados apresentados foi bastante satisfatório, tendo uma acurácia máxima de 99,79 para os dados de teste. As métricas utilizadas para a avaliação incluem matriz de confusão, precisão, recall e f1-score.

9. EXPECTATIVA PARA AS PROXIMAS ENTREGAS

A expectativa desse projeto tem como meta a criação de um software que diminua o trabalho exaustivo na identificação de frutas, contribuindo na conscientização ambiental, educacional e comercial, disponibilizando informações concretas a partir de parâmetros testados e validados.

10. LINK PARA O GITHUB

<https://github.com/grupos4g4/PROJAPLIC2>

11. REFERÊNCIA BIBLIOGRÁFICA

1. Albawi, Saad, Tareq Abed Mohammed, and Saad Al-Zawi. "Understanding of a convolutional neural network." *2017 international conference on engineering and technology (ICET)*. Ieee, 2017.
2. ALVES, Priscila Mello. "Inteligência artificial e redes neurais." *IPEA: Centro de Pesquisa em Ciência* (2020).
3. Der Kiureghian, Armen, and Ove Ditlevsen. "Aleatory or epistemic? Does it matter?." *Structural safety* 31.2 (2009): 105-112.

4. Dino. "IA: Maioria dos Brasileiros Já Utiliza Assistentes Virtuais." O Globo, 2 maio 2023, 17h04, <https://oglobo.globo.com/patrocinado/dino/noticia/2023/05/ia-maioria-dos-brasileiros-ja-utiliza-assistentes-virtuais.ghml>.
5. Garcin, Camille, et al. "PI@ ntNet-300K: a plant image dataset with high label ambiguity and a long-tailed distribution." *NeurIPS 2021-35th Conference on Neural Information Processing Systems*. 2021.
6. Israr Hussain, ., Qianhua He, Zhuliang Chen, & Wei Xie. (2018). Fruit Recognition dataset (V 1.0) [Data set]. Zenodo. <https://doi.org/10.5281/zenodo.1310165>
7. Kanda, Paul Shekonya, Kewen Xia, and Olanrewaju Hazzan Sanusi. "A deep learning-based recognition technique for plant leaf classification." *IEEE Access* 9 (2021): 162590-162613.
8. Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "ImageNet classification with deep convolutional neural networks." *Communications of the ACM* 60.6 (2017): 84-90
9. LeCun, Yann, et al. "Gradient-based learning applied to document recognition." *Proceedings of the IEEE* 86.11 (1998): 2278-2324.
10. LeCun, Yann, Koray Kavukcuoglu, and Clément Farabet. "Convolutional networks and applications in vision." *Proceedings of 2010 IEEE international symposium on circuits and systems*. IEEE, 2010.
11. Vinagreiro, Michel Andre Lima. *Classificação baseada em espaços de camadas convolucionais de redes CNNs densas*. Diss. Universidade de São Paulo, 2022.
12. Willis, Kathy. *State of the world's plants 2017*. Royal Botanic Gardens Kew, 2017.
13. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems* 32 (pp. 8024–8035). Curran Associates, Inc. Retrieved from <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>